ESE5023 第二次作业报告

Assignment 02 — Significant Earthquake Database, Shenzhen Air Temperature, IBTrACS, 自选数据集

姓名：伍奕　**学号：**12632770　**日期：**2026 年 10 月 21 日

数据来源：NOAA/NCEI Significant Earthquake Database（2150 B.C.–至今）；NOAA ISD 深圳宝安机场逐小时观测（1998–2022）； IBTrACS v04r00 全球最佳路径；NOAA GML 莫纳罗亚 CO_2 月均浓度。

工具：Python 3.13 + pandas 3.0 + numpy + matplotlib，全部代码见 `PS2.ipynb`。

合作声明：本报告的代码与文字由本人独立完成，未与他人协作。

摘要

本报告用 pandas 完成四组环境数据分析：①对公元前 2150 年以来的显著性地震记录，统计各国累计死亡人数、分析 Ms > 3.0 地震的年频次、并编写函数找出每个国家地震次数与最大地震；②解析 ISD 逐小时气温代码， 计算深圳宝安 1998–2022 年的月平均气温并检验其趋势；③处理 IBTrACS 全球热带气旋轨迹，分析强度排序、 空间分布、季节循环与年际异常；④自选莫纳罗亚 CO_2 月均浓度数据，做时间序列与五项统计检验。 主要结论：地震“变多”主要是观测与记录能力提升所致；深圳年均气温以约 **+0.29 °C/十年** 的速度上升； 全球最强热带气旋为 2015 年 Patricia（185 kt）；大气 CO_2 以约 **+2.4 ppm/年** 的速度增长且增长在加速。

1. 公元前 2150 年以来的显著性地震

1.1 各国累计死亡人数（前 20）

方法。读取 TSV 文件后先剔除没有年份的空行，按 `Country` 分组，对 `Total Deaths` 求和并降序排列。 该数据表同时给出 `Deaths` 与 `Total Deaths` 两列，二者只在 2,019 条同时有值的记录中的 67 条上不同 （后者把死亡描述文字里的数字也计入）。本报告采用 `Total Deaths`，理由是它包含 2004 年印度洋海啸的死亡人数， 若改用 `Deaths`，印尼只有 41,458 人而直接掉出前 20（`Total Deaths` 下为 283,485 人、排第 9）， 会严重低估实际伤亡。两列的全库总量分别为 7,520,810 与 7,800,521 人。

排名	国家	累计死亡人数	排名	国家	累计死亡人数
1	中国	2,106,526	11	巴基斯坦	143,714
2	土耳其	1,008,867	12	厄瓜多尔	134,445
3	伊朗	761,641	13	土库曼斯坦	110,412
4	意大利	417,297	14	秘鲁	97,009
5	叙利亚	358,326	15	希腊	83,658
6	海地	323,782	16	葡萄牙	82,572
7	日本	319,510	17	伊拉克	70,200
8	阿塞拜疆	319,251	18	智利	70,175
9	印度尼西亚	283,485	19	印度	63,413
10	亚美尼亚	175,000	20	以色列	58,368

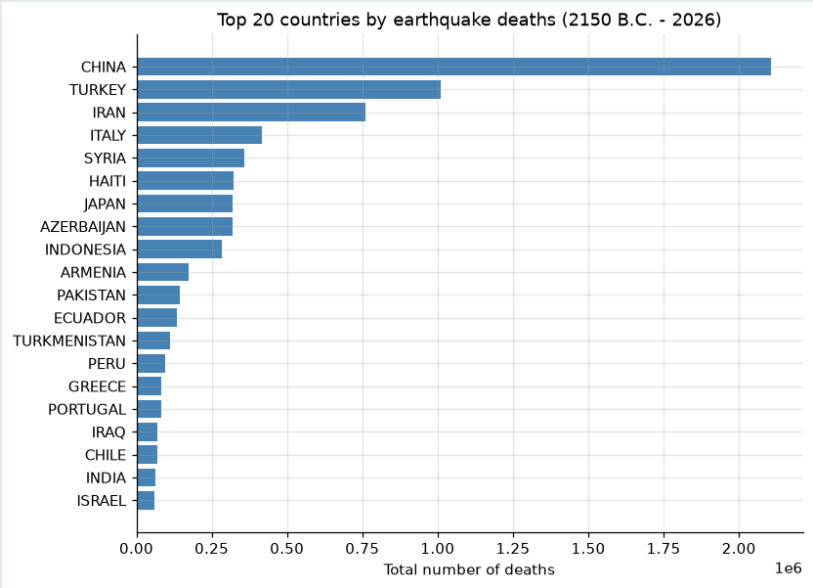


图 1　地震累计死亡人数前 20 的国家（2150 B.C.–2026）。

讨论。死亡人数高度集中在几条板块边界地震带上：中国、土耳其、伊朗三国合计约 390 万人，占全库的 52%。前列国家的共同点是人口稠密且位于大陆碰撞或转换断层带，历史强震造成的建筑倒塌是主要致死原因。

1.2 Ms > 3.0 地震的年频次及其趋势

方法。把 `Ms` 列转为数值型，筛选 > 3.0 的记录按年份计数，并计算 10 年滑动平均；图 2 左为完整记录，右为 1900 年后的仪器观测时期。

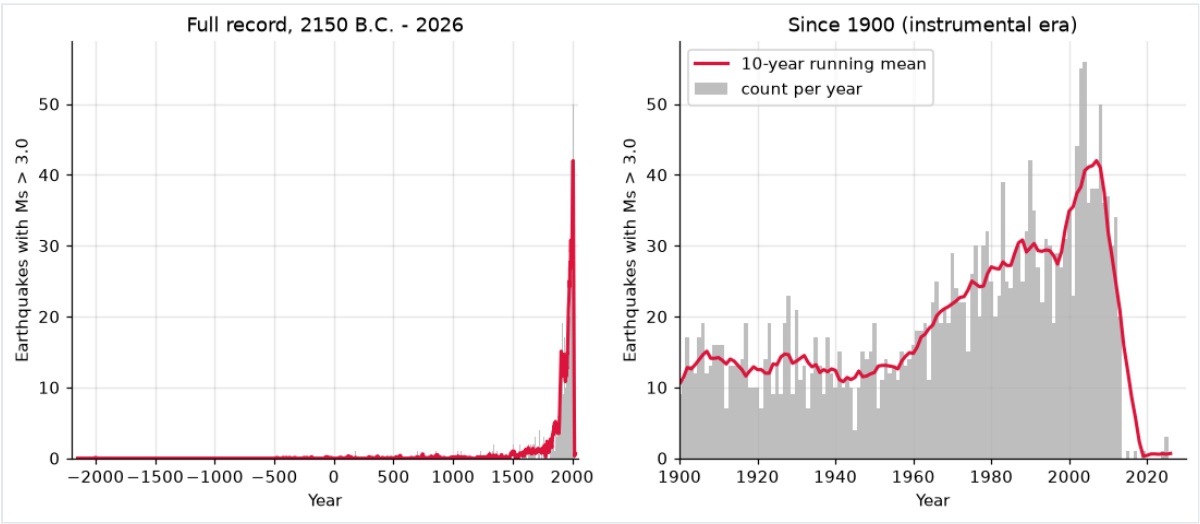


图 2　全球 Ms > 3.0 地震的年计数（灰色柱）与 10 年滑动平均（红线）。

结果。全库共 3,101 次 Ms > 3.0 的地震。1900 年以前年均仅 **0.19 次**，1900 年以后年均 **18.26 次**， 曲线在 1960–2000 年间快速抬升并在近年维持高位。

是否观察到趋势？曲线显著上升，但这**不是地震活动增强，而是记录能力的增强**： 1900 年前只有极少数台站，且目录只保留造成破坏的强震；1960 年代全球地震台网（WWSSN，后为 GSN）与卫星观测建立后， 强震目录才接近完整。因此该序列主要反映“观测系统成长曲线”，大地震的真实发生速率大致保持平稳。

> **数据陷阱：**2014 年以后该库几乎不再填写 `Ms`（现代地震改用 `Mw`）， 2014 年至今的 629 条记录里只有 7 条有 `Ms`，却有 627 条有通用 `Mag`。 所以图 2 右端接近零是缺测假象，不能据此说近年地震变少。

1.3 CountEq_LargestEq：每个国家的地震次数与最大地震

方法。编写函数 `CountEq_LargestEq(country)`，返回该国地震总数与最大地震的日期、地点； 震级优先用 `Ms`，若该记录无 `Ms` 则回退到通用 `Mag`，两列都缺时给出“震级未知”。 对全库 162 个国家逐一调用并按地震次数降序输出（无国家名的记录不计入），完整表另存为 `PS2_Q1_3_country_summary.csv`。

国家	地震次数	最大地震日期	地点与震级
中国	626	1920-12-16	甘肃、山西（Ms 8.6）
日本	429	869-07-13	三陆（Ms 8.6）
印度尼西亚	427	2004-12-26	苏门答腊西北外海（Ms 8.8）
伊朗	385	856-12-22	达姆甘（Ms 7.9）
土耳其	359	1939-12-26	埃尔津詹（Ms 7.8）

注：表中日期为数据库记录的年月日；古籍只记年份的事件按“YYYY”输出。全表共 162 行，含各国最大地震的地点与震级。

2. 深圳 1998–2022 年气温

数据。NOAA ISD 输出文件（站点 594930，深圳宝安机场），共 **235,674** 条逐小时记录， 时间范围 1998-01-01 至 2022-10-10。气温所在列 `TMP` 的格式为 `sTTTT,q` （见用户手册第 10–11 页 / POS 88–92）： `s` 为符号， `TTTT` 为以 0.1 °C 为单位的温度， `q` 为质控码 （0/1/5 = 通过，2/6 = 未通过，9 = 缺测）。

清洗方法（报告中需说明的过滤步骤）。

- 按逗号拆分 `TMP`，取出温度数值与质控码两段，数值除以 10 还原为摄氏度；
- **只保留质控码 0、1、5** 的记录，剔除 2、6（未通过质控）；
- 剔除缺测哨兵值 `+9999` （本数据中有 797 条，全部对应质控码 9）；
- 剔除物理上不可能的取值（±60 °C 以外）；
- 按自然月求平均，并丢弃小时数不足 300 的月份（数据末端 2022-10 只有 10 天，避免伪低值）。

清洗后保留 **234,864** 条有效温度（占 99.7%），得到 **298** 个月平均序列，范围 1998-01 至 2022-10； 有效温度均值 23.77 °C、标准差 5.82 °C、极值 1.8–38.0 °C。

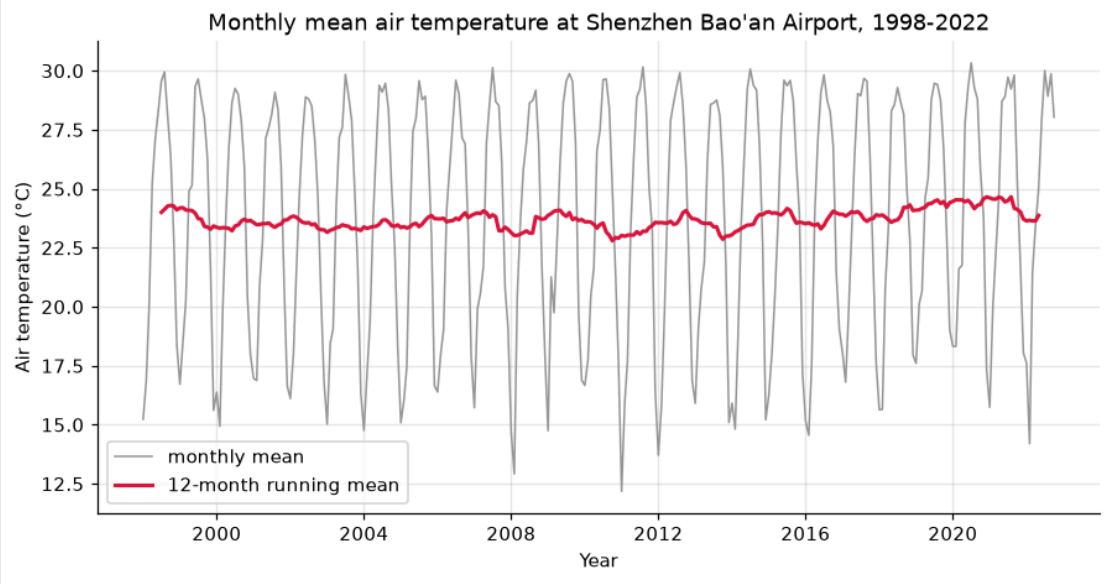


图 3　宝安机场月平均气温（灰）与 12 个月滑动平均（红）。

趋势检验。以“年 + 月/12”为自变量做最小二乘线性拟合，并对月平均序列先去季节（减去各月气候值）后重复拟合，同时给出年均序列的结果：

序列	趋势（°C/十年）	R^2
原始月平均（含季节循环）	+0.39	0.00
去季节后的月平均（距平）	+0.23	0.02
年平均	**+0.29**	**0.29**

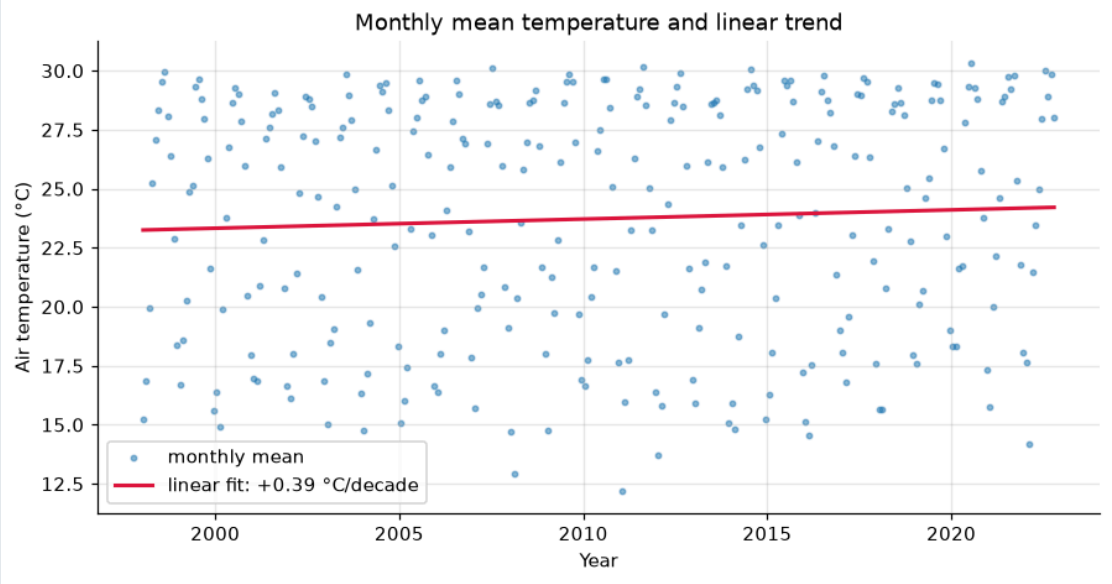


图 4　月平均气温散点与线性拟合直线。

讨论。1998–2022 年深圳宝安机场气温存在**微弱但一致的上升趋势**，年均约 +0.29 °C/十年，24 年累计约 0.7 °C。 五年段平均从 1998–2002 年的 23.63 °C 升到 2018–2022 年的 **24.32 °C**，最后五年是整段记录中最暖的五年。 原始月平均序列的 R^2 接近 0，是因为季节循环（约 12 °C 振幅）和天气尺度变率远大于长期趋势，这也是必须先做距平或年均再谈趋势的原因。 该升温既包含温室气体背景增暖，也包含深圳 / 宝安快速城市化带来的城市热岛效应。

3. IBTrACS 全球热带气旋

读取。按题目示例读取 17 列、`skiprows=[1,2]` 跳过单位行、把 `ISO_TIME` 解析为时间、 `NOT_NAMED` 视为缺测。在此之上做了两处必要修改：

- `keep_default_na=False`： pandas 默认会把 **北大西洋的洋盆代码** `NA` 当成缺失值， 导致整整一个洋盆被悄悄删掉（详见 3.3）；改为只把空串与 `NOT_NAMED` 视为缺失；
- `pd.to_numeric`：由于单位行的存在，16 个数值列被读成文本，其中 `WMO_WIND` 若是文本， 排序会按字符串比较（`"95" > "165"`），得到完全错误的最强风暴名单（详见 3.1）。

共读取 **707,176** 条轨迹点。

3.1–3.2 最强热带气旋（按 WMO_WIND 的最大值）

方法。按风暴编号 `SID` 分组，取 `WMO_WIND` 的最大值，降序排列；3.2 输出前 20 个风速值。

排名	名称	年份	最大风速（kt）
1	PATRICIA	2015	185
2	ALLEN	1980	165

3	WILMA	2005	160
4	LINDA	1997	160
5	GILBERT	1988	160
6	（未命名，1935 年）	1935	160
7	DORIAN	2019	160
8	RICK	2009	155
9	MITCH	1998	155
10	IRMA	2017	155

前 20 位风速集中在 150–185 kt，全部是成熟阶段的超强台风/飓风；帕特里夏（2015，东太平洋）以 185 kt、中心气压 872 hPa 位居首位。5,784 个风暴具有至少一个 `WMO_WIND` 值。

3.3 各洋盆的轨迹点数

洋盆	西北太平洋 WP	南印度洋 SI	北大西洋 NA	南太平洋 SP	东北太平洋 EP	北印度洋 NI	南大西洋 SA	合计
点数	236,576	160,668	124,881	67,119	62,412	55,401	119	707,176

西北太平洋占全部轨迹点的三分之一，是全球热带气旋最活跃的海域；南大西洋极少，仅 119 点。

3.4 轨迹点的空间分布

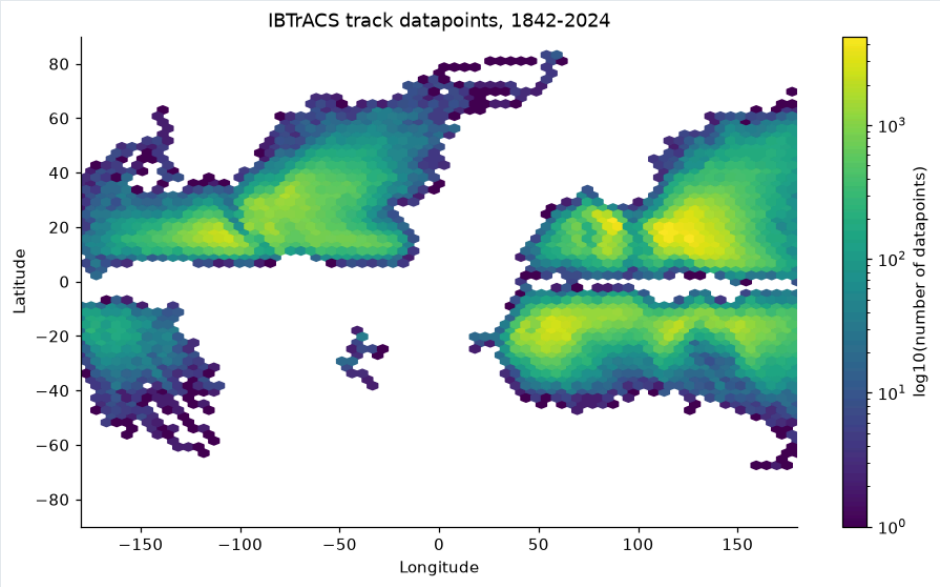


图 5　全部 IBTrACS 轨迹点的六边形分箱密度图（颜色为点数对数值）。

轨迹点密集区集中在 5°–25° 的热带—副热带洋面，形成西北太平洋、东北太平洋、北大西洋、南印度洋等几条明显的高密度带； 南大西洋与东南太平洋几乎空白，赤道附近（0°–5°）也明显稀疏，说明热带气旋生成需要足够的科氏力。

3.5 2018 年台风山竹（MANGKHUT）路径

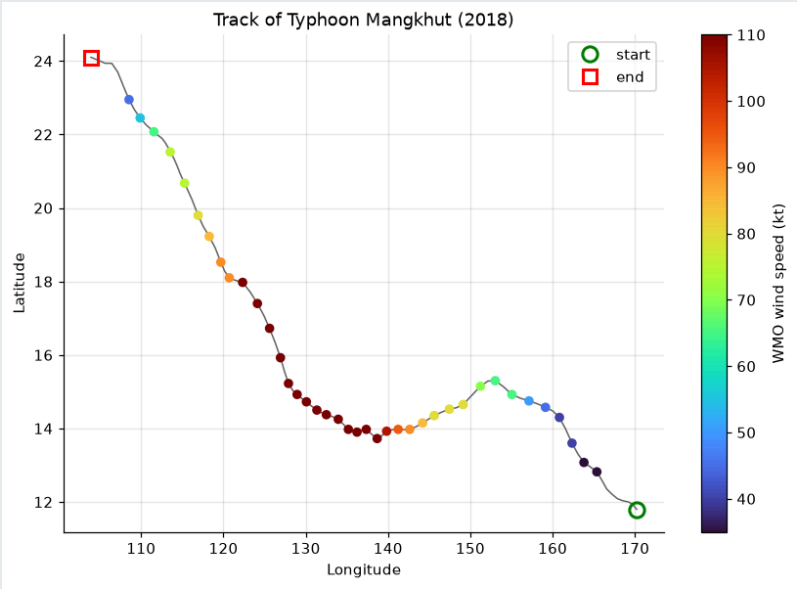


图 6　台风山竹（2018）的路径，颜色表示 WMO 风速，绿圈为起点、红方框为终点。

山竹于 2018-09-06 前后在 170°E 附近生成，向西偏北移动，在 130°E–140°E 一带达到最强（约 110 kt），穿过菲律宾吕宋岛后进入南海，最终在广东沿海登陆并西行进入广西境内消散；共 99 个轨迹点。

3.6–3.7 1970 年以来的 WP 与 EP 洋盆：逐日轨迹点数

筛选 `SEASON >= 1970` 且 `BASIN` 属于 `WP` / `EP` 的记录，得 **176,352** 个轨迹点、 **2,941** 个风暴，时间范围 1970-02-19 至 2022-10-12（其中 WP 122,301 点、EP 54,051 点）。 按 `ISO_TIME` 重采样到“日”，无观测的日期补 0，得到逐日点数序列。

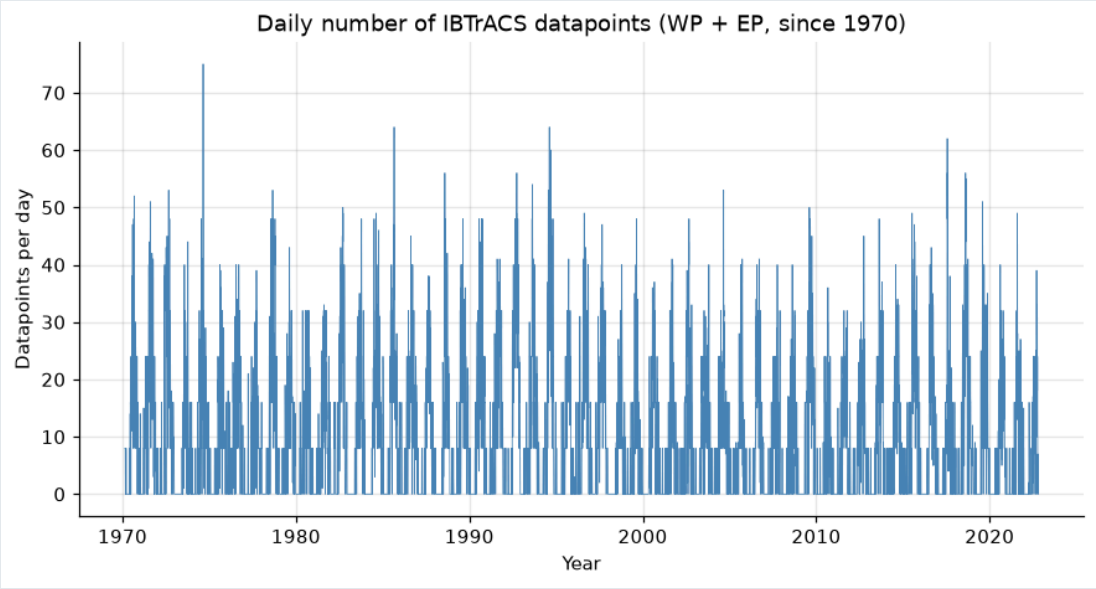


图 7　WP+EP 洋盆逐日轨迹点数（1970–2022）。

3.8 轨迹点数的日序气候态

按“一年中的第几天”分组求多年平均，得到气候态曲线（单峰型）：

- **峰值**出现在第 **222** 天（8 月 10 日），平均 **26.6** 点/日；
- **谷值**出现在第 **37** 天（2 月 6 日），平均仅 **0.2** 点/日。

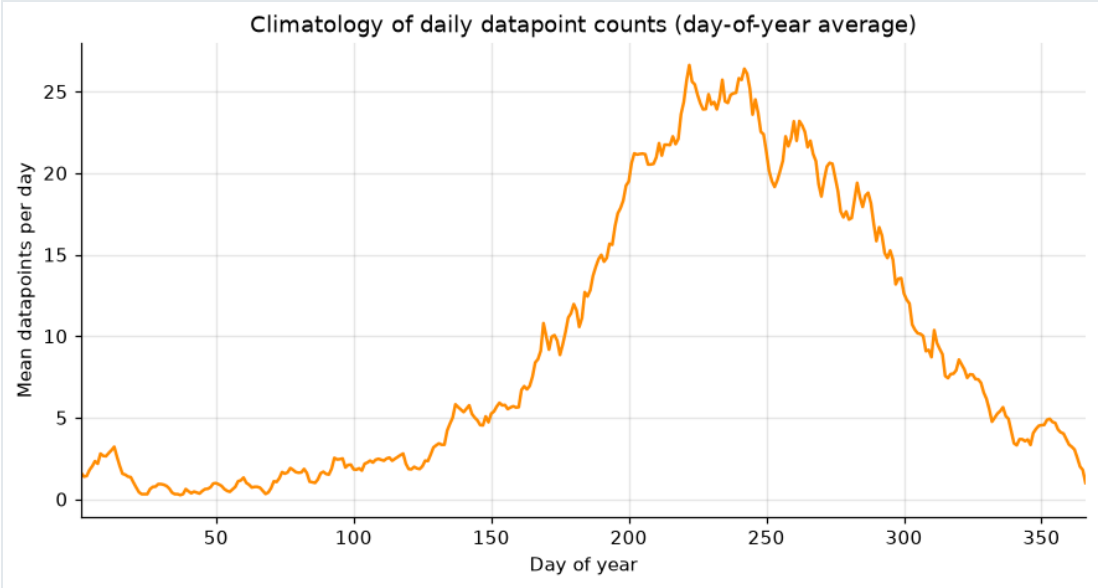


图 8　轨迹点数的日序气候态。

西北太平洋与东北太平洋的台风季集中在 7–10 月，2–4 月最不活跃，这与海表温度的季节变化和季风槽位置一致。

3.9–3.10 距平及其年际变化

把逐日点数减去同日序的气候值得到距平序列（均值 0、标准差 7.39 点/日），再按年求平均。

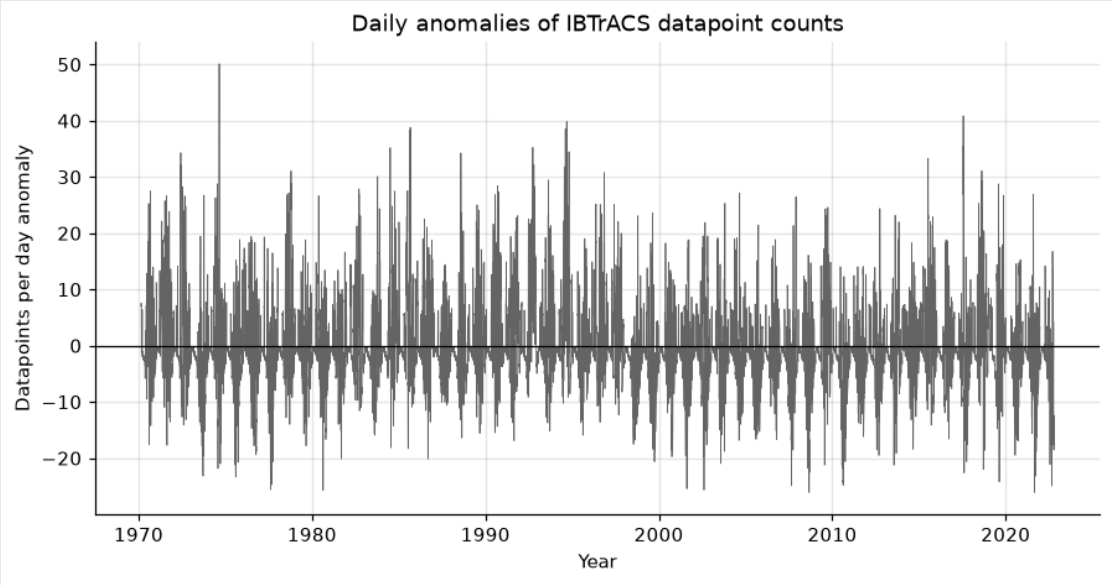


图 9　逐日轨迹点数距平序列。

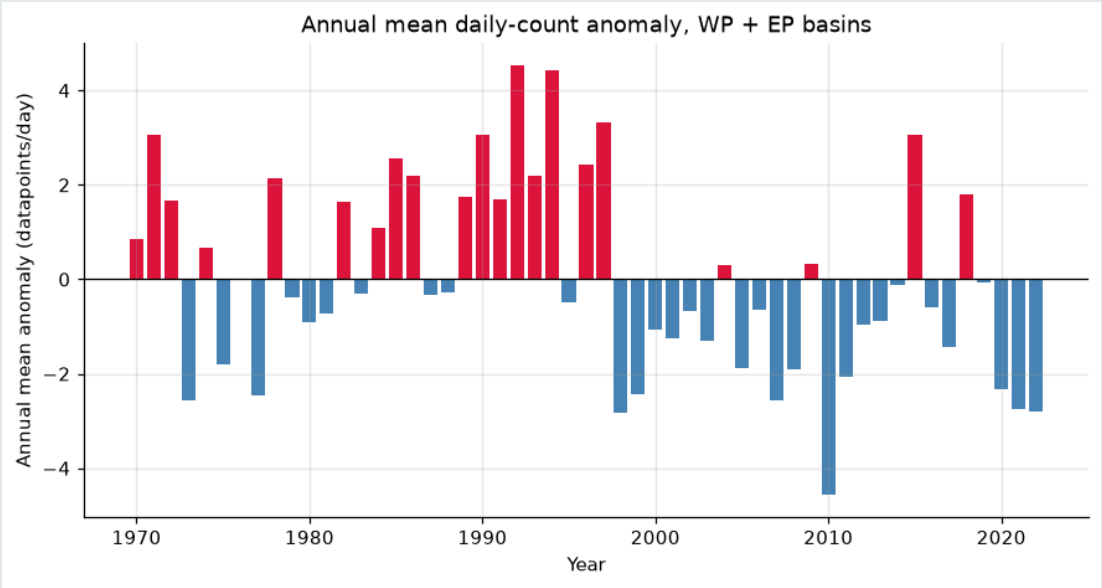


图 10　年平距平（红：正异常，蓝：负异常）。

哪些年份异常? 正距平最显著的年份是 **1992（+4.54）**、**1994（+4.42）**、**1997（+3.33）**、1990 与 2015（各 +3.07）； 负距平最显著的是 **2010（−4.57）**、1998（−2.83）、2022（−2.79）、2021（−2.75）、2007（−2.56）。 正异常年多为强厄尔尼诺年（1992、1994、1997、2015），东太平洋增暖使 EP 洋盆风暴显著增多；1998 与 2021–2022 处于拉尼娜位相， 东太平洋被抑制，因而明显偏少。2010 年是最强负异常，与该年拉尼娜及西北太平洋活动偏弱一致。

注：本序列衡量的是“轨迹点数”，会同时受风暴个数、寿命与定强定数间隔（3 小时 vs 6 小时）的影响； 1970 年代平均约 9.4 点/日、1990 年代最高 10.7 点/日、2000 年代 8.1 点/日、2010 年代 8.6 点/日，整体没有单调趋势， 因此异常诊断以“哪年偏多/偏少”为主，不宜直接解读为风暴频率的长期变化。

4. 自选数据集：莫纳罗亚大气 CO_2（1958–2026）

数据。来自 NOAA 全球监测实验室（GML）的 `co2_mm_mlo.csv`，为夏威夷莫纳罗亚观测站的月平均 CO_2 浓度，带 `year, month, decimal date, average, deseasonalized, ndays, sdev, unc` 等字段，最长时间跨度 1958 年至今。

4.1 清洗。文件前 40 行是注释，用 `comment='#'` 跳过；以 `-9.99` 标记缺失月份并剔除； 以 `(year, month)` 去重；剔除 250–500 ppm 之外的异常值。清洗后得到 **823** 个月（1958-03 至 2026-09），无残留缺失值。 注意 `ndays` 在早期记录中为 −1 但 `average` 有效，因此不能只用 `ndays > 0` 过滤，否则会误删 1958–1974 年的全部数据。

4.2 时间序列。

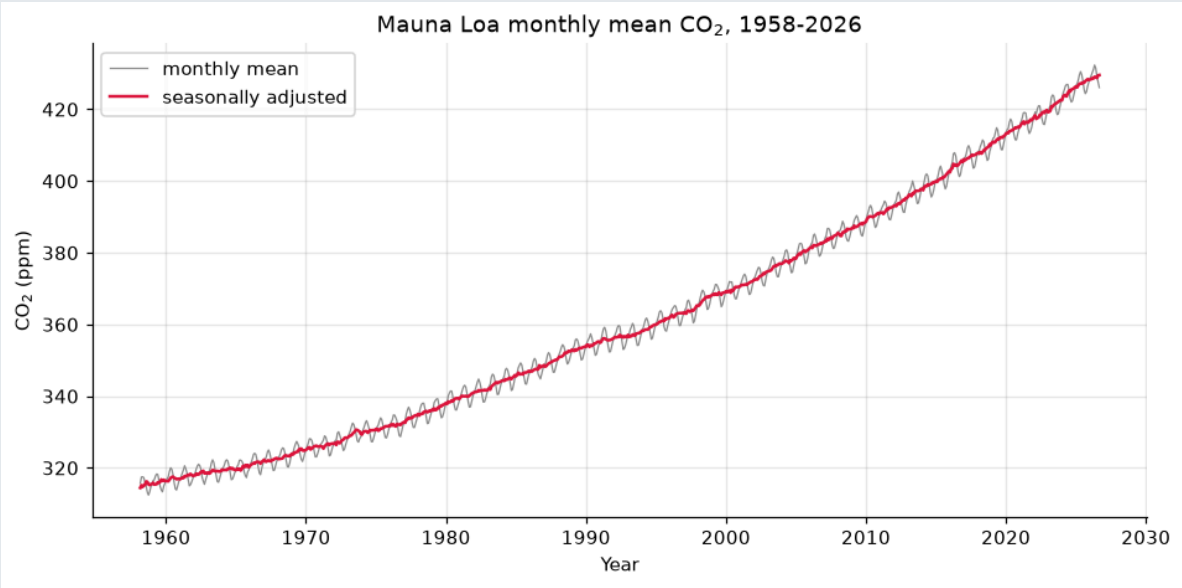


图 11　莫纳罗亚月平均 CO_2（灰）与季节调整后的序列（红）。

曲线呈稳定的指数型上升，叠加明显的年周期锯齿；季节调整后得到平滑的长期增长趋势。

4.3 五项统计检验。

检验	结果	含义
① 线性趋势	+16.7 ppm/十年（R^2 = 0.979）	整段记录平均每年升高约 1.67 ppm，且拟合极好
② 季节循环	振幅 6.58 ppm，5 月最高、10 月最低	北半球植被春夏吸收、秋冬释放造成的“锯齿”
③ 增长率变化	1958–1980：10.4 ppm/十年；2005 年后：23.7 ppm/十年	增长在**加速**，约翻了一倍多
④ 自相关	滞后 1 阶自相关 0.999（去季节后 1.000）	序列高度平滑、强记忆性，逐月之间几乎无独立信息
⑤ 分布特征	均值 361.4 ppm，标准差 33.5 ppm，偏度 0.38，范围 312.4–432.3 ppm	右偏（近年高值拉长上尾）；线性拟合残差标准差仅 3.07 ppm

讨论。五项检验互相印证：CO_2 不是简单线性增长而是**加速增长**（②③⑤ 中残差集中在近十年偏高也说明这一点），季节循环证明观测受北半球陆地生物圈控制，高自相关则意味着任何短期（月尺度）波动都不具独立统计意义，做趋势估计必须用长序列或年均值。20 世纪中叶以来化石燃料排放的持续增长是加速增长的主因。

5. 小结与踩坑记录

四个题目共用的核心流程与讲义一致：`read_csv` 读入 → 条件筛选 → `groupby` 聚合 → `sort_values` 排序 → `to_csv` 输出；第 2、3 题额外用到了 `resample` / `rolling` 等时间序列方法与最小二乘拟合。全部代码与运行输出见 `PS2.ipynb`（62 个单元、11 幅图、无报错）。

> **三个值得记录的数据陷阱（都直接影响结论）：**
> ① `Ms` 在 2014 年后基本停更，用 Ms 统计会把近年地震数算成 0；
> ② IBTrACS 的洋盆代码 `NA` 会被 pandas 当成缺失值，不处理就丢失 124,881 个北大西洋轨迹点；
> ③ `WMO_WIND` 以文本读入时必须先转数值，否则“最强风暴”会变成一批 95 kt 的 1950 年代风暴。